

Informe de Arquitectura y Configuración: FitCore

Proyecto: Agente Conversacional Dialogflow

Autor: Manuel Pérez Perdomo.

1. Visión General del Sistema

FitCore es un agente de inteligencia artificial conversacional de voz end-to-end, diseñado para una empresa especializada en soluciones deportivas y nutrición personal. La capa de Comprensión del Lenguaje Natural (NLU) está desarrollada en Dialogflow ES. Este agente se integra mediante un webhook que simula la lógica de negocio y realiza consultas a una base de conocimiento técnica utilizando la arquitectura RAG (Retrieval-Augmented Generation).

Flujo de Arquitectura de Voz End-to-End:

- El usuario interactúa mediante voz a través de un micrófono.
- Un motor STT (Google Speech-to-Text o Whisper) transcribe el audio a texto.
- Dialogflow ES procesa la intención del usuario a través de su API.
- El Webhook de FitCore ejecuta la lógica de negocio o RAG si es necesario.
- Dialogflow devuelve el texto de respuesta (fulfillmentText).
- Un motor TTS (Azure Speech Service) convierte el texto a voz.
- El usuario escucha la respuesta final por el altavoz.

2. Componentes del Agente

El sistema consta de un total de 17 intents (15 personalizados y 2 de sistema) y 5 entidades personalizadas principales.

Entidades Personalizadas

Entidad	Tipo	Patrón de Reconocimiento	Ejemplo
Codigo_Cliente	Regex p	[A-Z]{2}\d{6}	AB123456
Numero_Pedido	Regex p	PED-\d{5}	PED-00123
Codigo_Incidencia	Regex p	INC-\d{4}	INC-0042

Tipo_Incidencia	Enum	averia, retraso, etc.	retraso
Objetivo_Deportivo	Enum	perdida_de_peso, etc.	definicion

Intents Principales y Uso de Webhook

Intent	Tipo de Interacción	Requiere Webhook
Consultar_Estado_Pedido	Multi-turno	Sí
Abrir_Incidencia	Multi-turno	Sí
Consultar_Incidencia	Simple	Sí
Cerrar_Incidencia	Multi-turno	No (Solo confirmación)
Consultar_Plan_Nutricional	Slot-fill	Sí (RAG)
Consultar_Plan_Entrenamiento	Slot-fill	Sí (RAG)
Consultar_Productos / Envios	Simples / Estáticos	No
Cambiar_Tema	Interrupción	No

3. Gestión de Contextos y Resiliencia

El diseño conversacional se basa en contextos para mantener la coherencia temporal de la interacción.

- El contexto **sesion_activa** (lifespan de 99) protege los intents personalizados para garantizar que el usuario pase por el saludo inicial.
- Los contextos cortos (lifespan de 2 a 5) se utilizan para activar flujos de confirmación (yes/no) en pedidos e incidencias, así como para habilitar preguntas de seguimiento en los planes deportivos.
- El sistema soporta interrupciones a través del intent **Cambiar_Tema**.
- Este intent de interrupción limpia todos los contextos activos (**resetContexts: true**) y restaura únicamente la **sesion_activa**, permitiendo al usuario cambiar de flujo sin romper el estado del bot.

4. Flujos Conversacionales Clave

- **Consulta de Pedido:** Extrae el número de pedido y código de cliente, consulta el webhook para obtener estado y fecha estimada, y ofrece opciones de continuidad.
- **Apertura de Incidencia:** Identifica automáticamente el tipo de problema, recopila datos del cliente, solicita confirmación y delega al webhook la generación de un código **INC-XXXX**.

- **Planes Personalizados (RAG):** El usuario indica su objetivo deportivo, el webhook realiza una consulta en la base de conocimiento y devuelve una respuesta estructurada, sugiriendo servicios cruzados.

5. Requisitos de Despliegue

- El agente debe crearse en Dialogflow ES (zona `europa-west1`, idioma español).
- La restauración puede realizarse mediante la importación estructurada de un archivo ZIP que contenga las carpetas `intents/` y `entities/`.
- El Fulfillment requiere un servidor Express en Node.js, expuesto mediante herramientas como ngrok para pruebas locales.
- Para evolucionar hacia un entorno RAG en producción, se recomienda integrar una base de datos vectorial (Qdrant) y un modelo de lenguaje extenso (OpenAI GPT-4, Anthropic Claude) en el backend.